

Universitat Politècnica de Catalunya
ETSETB / FIB

Motor de Recomendación Cinematográfica de Altas Prestaciones Basado en Redes Neuronales y Metadatos Heterogéneos

Propuesta de Proyecto: Caracterización de Datos Masivos, Revisión del Estado del Arte y Justificación Tecnológica

Computació d'Altes Prestacions i Intel · ligència Artificial (CPIA)

Autores:
Arnau Montull
Uriel Martínez



7 de octubre de 2026

1. Definición del Problema a Resolver

En el ámbito del entretenimiento digital bajo demanda, los sistemas de recomendación constituyen el componente algorítmico crítico encargado de mitigar la sobrecarga informativa del usuario. No obstante, diseñar un motor de recomendación escalable sobre catálogos con decenas de miles de películas impone restricciones estructurales severas derivadas de la naturaleza de los datos:

1. **Esparcidad extrema de datos (*High Sparsity*):** En matrices de interacción usuario-película a gran escala, la inmensa mayoría de las combinaciones posibles carecen de observación. Un usuario medio evalúa una fracción inferior al 0.1 % del catálogo, lo que genera una matriz con un nivel de dispersión superior al 99.8 %. Los métodos algebraicos puros sufren inestabilidad numérica ante este vacío informativo.
2. **Sesgo de popularidad (*Popularity Bias*):** Las interacciones observadas siguen una ley de potencias fuertemente desbalanceada. Los modelos de aprendizaje supervisado tienden a maximizar métricas globales recomendando sistemáticamente un núcleo reducido de películas hiperpopulares (*blockbusters*), invisibilizando el catálogo de nicho o cine de autor (*long-tail*) que concentra el interés diferencial de los usuarios cinéfilos.
3. **El desafío del arranque en frío (*Cold-Start*):** Los enfoques de filtrado colaborativo puro colapsan al incorporar películas recién estrenadas o al recibir usuarios nuevos (por ejemplo, mediante la importación de historiales externos de Letterboxd), ya que requieren un historial denso previo para asignar vectores latentes válidos.
4. **Latencia y escalabilidad en inferencia (Requisito CPIA):** Evaluar funciones de predicción complejas contra la totalidad del inventario en tiempo real resulta computacionalmente inviable. Se requiere un desacoplamiento algorítmico que traslade el grueso del cómputo a fases precomputadas y aproveche la vectorización SIMD y el paralelismo multihilo en CPU.

1.1. Formulación Matemática del Objetivo

Sea $\mathcal{U}$ el conjunto de usuarios con cardinalidad $|\mathcal{U}| = N$ y $\mathcal{I}$ el inventario de películas con cardinalidad $|\mathcal{I}| = M$. El espacio de interacciones se formaliza como una matriz dispersa $\mathbf{R} \in \mathbb{R}^{N \times M}$, donde cada elemento $r_{ui} \in [0.5, 5.0]$ representa una valoración explícita o la ausencia de interacción ($r_{ui} = \emptyset$).

El objetivo no radica en una regresión puntual para estimar valores numéricos de notas individuales, sino en un problema de **Aprendizaje de Ordenamiento (*Learning to Rank*) y Recuperación Top-K**. El sistema debe proyectar usuarios e ítems a un espacio latente métrico compartido $\mathbb{R}^d$ ($d \ll M$), produciendo una puntuación de afinidad $\hat{s}(u, i)$ que ordene las preferencias relativas:

$$\hat{s}(u, i) > \hat{s}(u, j) \quad \forall\, i \in \mathcal{I}_u^+,\ j \in \mathcal{I} \setminus \mathcal{I}_u^+ \tag{1}$$

donde $\mathcal{I}_u^+$ denota el conjunto de obras con afinidad positiva para el usuario y $\mathcal{I} \setminus \mathcal{I}_u^+$ representa el catálogo no observado o irrelevante.

2. Identificación y Caracterización de las Fuentes de Datos

Para abordar simultáneamente el modelado colaborativo, el arranque en frío y el sesgo de popularidad, el proyecto recurre a la combinación y cruce relacional de tres conjuntos de datos heterogéneos (Tabla 1):

2.1. MovieLens 32M: Núcleo Cuantitativo Colaborativo

Publicado por GroupLens Research en su versión oficial más exhaustiva [1], recoge el comportamiento continuado de usuarios hasta octubre de 2023[cite: 29]. Proporciona:

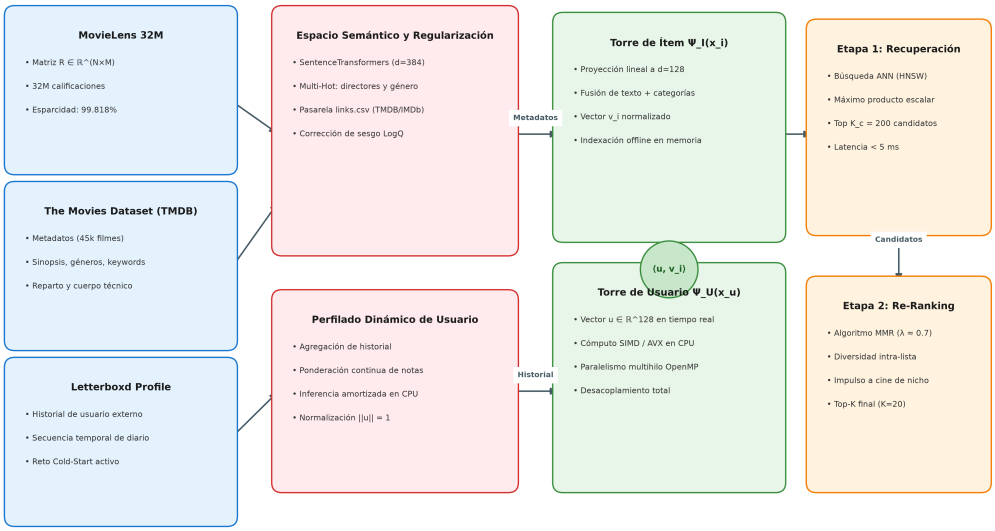


Figura 1: Esquema conceptual del problema: integración de datos masivos y heterogéneos, modelado desacoplado y pipeline de inferencia eficiente en dos fases.

Tabla 1: Especificaciones cuantitativas de los conjuntos de datos analizados.

Fuente de Datos	**Usuarios (N)**	**Ítems (M)**	**Volumen / Registros**	**Dispersión**
MovieLens 32M	200 948	84 432	32 000 204 ratings	99.811 %
The Movies Dataset (TMDB)	—	45 466	Metadatos y sinopsis	—
Letterboxd Export Format	Perfil real	Catálogo	Secuencia temporal	Específico

- **`ratings.csv`** ($\approx$ 700 MB): Registros estructurados en cuádruplas (userId, movieId, rating, timestamp)[cite: 29]. Las calificaciones abarcan una escala ordinal de 10 niveles discretos (de 0.5 a 5.0 con incrementos de 0.5 estrellas)[cite: 36, 41].
- **`links.csv`**: Tabla relacional fundamental que asocia el identificador interno `movieId` con las claves de `imdbId` y `tmdbId`, actuando como puente de enlace hacia la información semántica[cite: 41, 43].

2.2. Análisis Empírico de la Distribución de Datos

El procesamiento directo de los 32 millones de registros revela dos propiedades estadísticas críticas que condicionan el diseño del sistema (Figura 2):

1. **Concentración extrema en la cola pesada (*Long-Tail*):** Del catálogo evaluado (84 432 películas con al menos un voto), el 10 % superior de títulos más populares (8 443 filmes) concentra el **95.70 % de todas las interacciones del sistema**. El 90 % restante del inventario se reparte únicamente el 4.30 % de las calificaciones registradas. Cualquier modelo optimizado sin regularización de popularidad tenderá a ignorar este 90 % del inventario.
2. **Asimetría de calificaciones (*Positive Skew*):** Las notas otorgadas presentan una clara asimetría hacia valores positivos: las notas ≥ 3.5 representan la gran mayoría del volumen total. Esto confirma que el usuario tiende a ver y calificar títulos que espera disfrutar, haciendo aconsejable tratar las notas altas como retroalimentación implícita de afinidad y ponderar el historial.

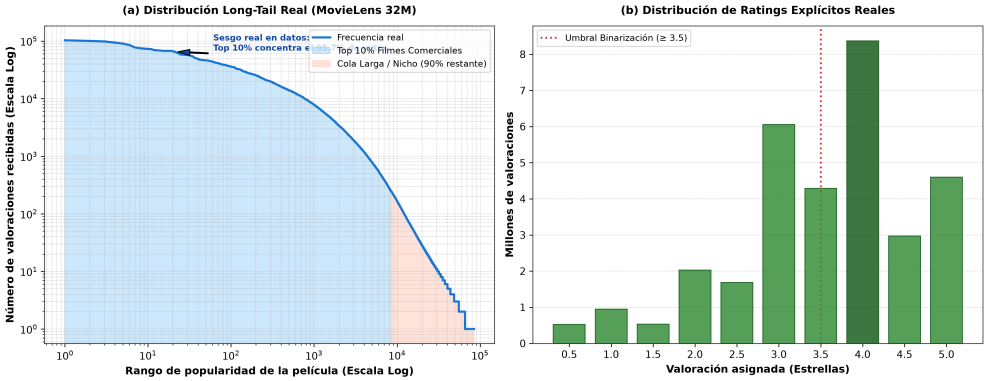


Figura 2: Distribución empírica obtenida sobre MovieLens 32M: (a) curva de potencia con el 95.70 % de interacciones concentradas en el Top 10 %, y (b) histograma de calificaciones con sesgo positivo.

2.3. The Movies Dataset (TMDB) y Metadatos Semánticos

Para dotar de contexto intrínseco al sistema y solventar el arranque en frío, se integran los metadatos de The Movie Database:

- **Atributos descriptivos y sinopsis (`movies_metadata.csv`):** Texto narrativo (*overview*), año de estreno, presupuestos y géneros cinematográficos.
- **Cuerpo técnico y reparto (`credits.csv`):** Directores, guionistas, equipo de fotografía y actores principales representados en estructuras tabulares deserializadas.
- **Palabras clave argumentales (`keywords.csv`):** Descriptores temáticos para enriquecer el perfil semántico.

2.4. Letterboxd Export Format: Caso de Uso en Entorno Real

Para validar el sistema en un entorno real de explotación, se adopta el esquema de exportación de Letterboxd (`watched.csv`, `ratings.csv`, `diary.csv`). Esto permite recrear el escenario en el que un

usuario nuevo introduce su diario cinematográfico personal cronológico, permitiendo medir la latencia y la calidad de la recomendación ante perfiles no incluidos en el entrenamiento inicial.

Tabla 2: Esquema de integración y normalización relacional de atributos.

Dataset Origen	**Campo Crudo**	**Transformación / Ingeniería de Atributos**	**Uso en el Modelo**
MovieLens	`movieId`, `rating`	Binarización implícita ponderada por r_{ui}	Torre de Usuario
TMDB	`overview`	Embedding semántico denso ($d = 384$) con MiniLM	Torre de Ítems
TMDB	`genres`, `director`	Codificación dispersa Multi-Hot	Torre de Ítems
MovieLens	`links.csv`	Mapeo relacional (`tmdbId` $\leftrightarrow$ `movieId`)	Fusión de datos
Letterboxd	`diary.csv`	Secuencia cronológica y agregación online	Inferencia en tiempo real

3. Estado del Arte y Revisión Bibliográfica

La literatura en sistemas de recomendación abarca múltiples paradigmas formales, cada uno con compromisos computacionales y de expresividad diferenciados frente a grandes catálogos:

3.1. Taxonomía de Soluciones Previas

1. **Factorización Matricial Clásica (SVD / ALS):** Popularizada durante el *Netflix Prize* [2], descompone la matriz observada en factores latentes lineales $\mathbf{R} \approx \mathbf{P}\mathbf{Q}^\top$ mediante Mínimos Cuadrados Alternados[cite: 13, 14, 15]. Aunque es computable de forma multihilo[cite: 15], su carácter estrictamente lineal le impide asimilar descripciones textuales o atributos densos, fracasando completamente ante el arranque en frío.

2. **Autoencoders Lineales Analíticos (EASE^R):** Propuesto por Steck [7], aprende una matriz de pesos ítem-ítem $\mathbf{B}$ con diagonal nula mediante una solución exacta en forma cerrada. No obstante, exige invertir la matriz de Gram $\mathbf{G} = \mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}$, cuya complejidad temporal es $\mathcal{O}(M^3)$ y espacial $\mathcal{O}(M^2)$. Para el catálogo de MovieLens ($M \approx 84\,000$), almacenar dicha matriz requeriría más de 28 GB de memoria RAM para la inversión, resultando inviable en procesadores convencionales y sin soporte para ítems nuevos.

3. **Autoencoders Variacionales Bayesianos (Multi-VAE):** Introducido por Liang et al. [5], modela las preferencias como un proceso generativo con verosimilitud multinomial. Aunque ofrece excelente precisión en ranking, la capa de normalización softmax sobre el catálogo completo penaliza la latencia de inferencia sin GPUs dedicadas.

4. **Factorización Neuronal Colaborativa (NCF / NeuMF):** Diseñado por He et al. [4], combina un producto de Hadamard con un perceptrón multicapa (MLP) para capturar no linealidades complejas[cite: 21]. Sin embargo, su cuello de botella operativo es crítico: las capas densas acopladas impiden precomputar representaciones independientes. Cada recomendación exige evaluar la red completa contra cada filme ($\mathcal{O}(M \cdot C_{\text{MLP}})$), haciendo prohibitiva la respuesta en milisegundos.

5. **Modelos Secuenciales con Auto-Atención (SASRec):** Kang y McAuley [6] modelan secuencias temporales mediante transformadores unidireccionales. Destacan capturando dependencias dinámicas, pero su coste computacional cuadrático $\mathcal{O}(L^2 d)$ respecto a la longitud de sesión desvía el foco de la recuperación eficiente sobre catálogo masivo.

6. **Redes Neuronales sobre Grafos (LightGCN):** He et al. [9] simplifican la convolución de grafos a difusión lineal sobre la matriz de adyacencia bipartita. Aunque maximiza el aprovechamiento estructural, su alta huella de memoria para el grafo y el acceso disperso a punteros complican la vectorización uniforme en CPU.

7. **Arquitecturas de Dos Torres y Recuperación Industrial:** Introducidas por Covington et al. [3] y formalizadas por Yi et al. [8], desacoplan al usuario y al ítem en torres neuronales diferenciadas[cite: 20, 21]. La inferencia se reduce a un producto escalar en espacio continuo, resolviendo la búsqueda mediante algoritmos de Vecinos Más Cercanos Aproximados (*ANN*) en tiempo sublineal $\mathcal{O}(\log M)$.

8. **Diversificación y Reordenamiento con MMR:** Carbonell y Goldstein [10] formularon el criterio de Relevancia Marginal Máxima (*Maximal Marginal Relevance*), balanceando afinidad del usuario con novedad temática intra-lista para evitar listas redundantes.

Tabla 3: Comparativa analítica de paradigmas frente a los criterios del proyecto.

Paradigma	Inferencia Top-K	Consumo Memoria	Cold-Start	Metadatos	Idoneidad CPU
SVD / ALS [2]	$\mathcal{O}(M \cdot d)$	$\mathcal{O}((N+M)d)$	Nulo	Limitada	Alta (BLAS multi-hilo)[cite: 13, 15]
EASE^R [7]	$\mathcal{O}(\lvert I_u \rvert M)$	$\mathcal{O}(M^2)$ (Crítico)	Nulo	Incompatible	Baja (inversión $\mathcal{O}(M^3)$)
NeuMF [4]	$\mathcal{O}(M \cdot C_{\text{MLP}})$	$\mathcal{O}((N+M)d)$	Moderado	Posible	Muy baja (MLP acoplado)[cite: 21]
LightGCN [9]	$\mathcal{O}(d \log M)$	$\mathcal{O}((N+M)d + \lvert \mathbf{A} \rvert)$	Bajo	Homogéneo	Media (acceso disperso)
Two-Tower [8]	$\mathcal{O}(d \log M)$ (ANN)	$\mathcal{O}((N+M)d)$	**Excelente**	**Nativa y flexible**	**Sobresaliente (SIMD/OMP)**[cite: 21, 24]

4. Justificación Tecnológica del Enfoque Propuesto

A partir del análisis de datos y la revisión de la literatura, se justifica la adopción de una **estrategia híbrida en dos etapas desacopladas** (Figura 3):

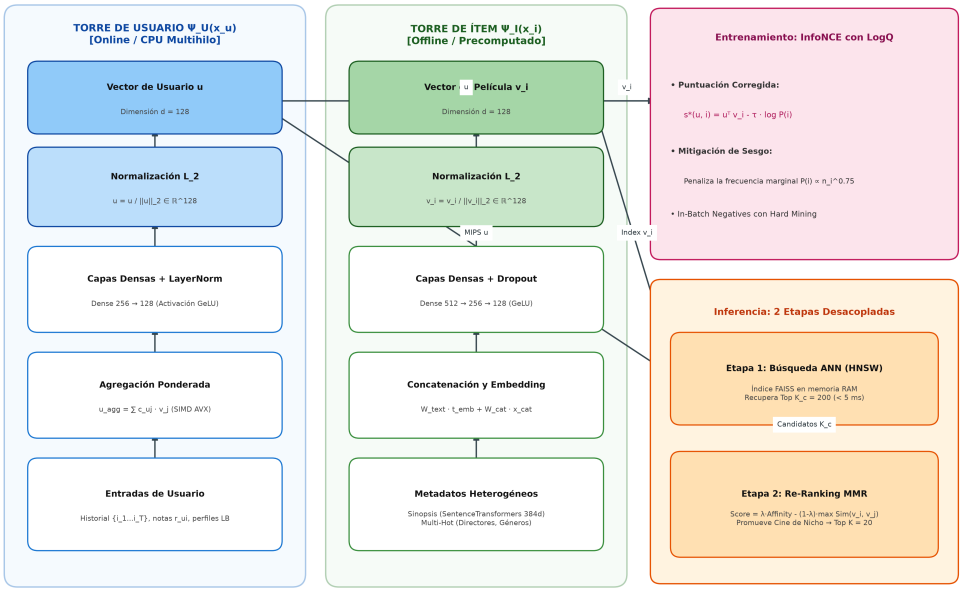


Figura 3: Arquitectura propuesta: desacoplamiento en dos etapas (Recuperación Two-Tower con búsqueda vectorial ANN y Reordenamiento con diversificación MMR).

4.1. Justificación de la Arquitectura Two-Tower (Etapa 1)

Para satisfacer la restricción de catálogo masivo (84 000 títulos) y tiempos de respuesta interactivos sin GPU, la red desacopla totalmente las dos entidades[cite: 20, 21]:

$$\hat{s}(u,i) = \langle \mathbf{u}, \mathbf{v}_i \rangle = \Psi_U(\mathbf{x}_u)^\top \Psi_I(\mathbf{x}_i), \quad \mathbf{u}, \mathbf{v}_i \in \mathbb{R}^{128} \tag{2}$$

- **Resolución del Arranque en Frío:** La Torre de Ítem proyecta sinopsis (vía embeddings de *SentenceTransformers*) y codificaciones Multi-Hot de directores y géneros. Para un título recién estrenado sin calificaciones previas, el vector $\mathbf{v}_i$ se calcula directamente a partir de sus metadatos.
- **Inferencia Logarítmica:** Al ser un producto escalar, los vectores de todas las películas se precomputan offline e indexan en memoria RAM mediante estructuras de grafos jerárquicos navegables (*HNSW*)[cite: 21, 24]. La recuperación de los $K_c = 200$ candidatos principales se resuelve en $\mathcal{O}(d \log M)$ con latencia inferior a 5 ms[cite: 21].
- **Mitigación del Sesgo de Popularidad:** Inspirado en Yi et al. [8], el entrenamiento contrarresta la concentración empírica del 95.70 % corrigiendo las puntuaciones contrastivas mediante la probabilidad marginal del ítem: $s^*(u,i) = \mathbf{u}^\top \mathbf{v}_i - \tau \log P(i)$, donde $P(i) \propto n_i^{0.75}$ penaliza la sobreexposición artificial de superventas[cite: 22, 23].

4.2. Justificación del Reordenamiento con MMR (Etapa 2)

La primera etapa prioriza relevancia global. Para combatir la redundancia y rescatar obras de autor de la cola larga, la segunda etapa refina la lista final ($K = 20$) aplicando Relevancia Marginal Máxima [10]:

$$i^* = \arg\max_{i \in \mathcal{C} \setminus \mathcal{S}} \left[\lambda \cdot \text{Score}_{\text{recup}}(u,i) - (1-\lambda) \max_{j \in \mathcal{S}} \text{Sim}(\mathbf{v}_i, \mathbf{v}_j) \right] \tag{3}$$

fijando $\lambda \in [0.65, 0.75]$. Este mecanismo garantiza diversidad genérica y estilística dentro de la lista entregada al usuario.

5. Plan de Computación Paralela y Optimización HPC (CPIA)

El diseño traslada el cuello de botella computacional a rutinas numéricas ideales para explotación paralela en arquitecturas CPU multinúcleo comerciales:

1. Paralelización con OpenMP en C/C++: El cálculo simultáneo de perfiles de usuario y el cálculo masivo de afinidades y re-ranking sobre los candidatos recuperados se implementará mediante bucles paralelizados con balanceo de carga dinámico [11]:

```
#pragma omp parallel for schedule(dynamic, 64)
for (int u = 0; u < num_usuarios; ++u) {
    calcular_perfil_usuario(&usuarios[u], items_db, dim_embedding);
    evaluar_similitudes_simd(&usuarios[u], candidatos, top_k);
}
```

2. Vectorización SIMD (AVX2 / AVX-512): Dado que los vectores de usuario e ítem poseen dimensión fija ($d = 128$), el producto interno $\langle \mathbf{u}, \mathbf{v}_i \rangle$ se optimizará alineando memoria a 32/64 bytes e invocando instrucciones intrínsecas FMA (*Fused Multiply-Add*), ejecutando hasta 8 o 16 operaciones float por ciclo por núcleo.

3. Plan de Evaluación de Escalabilidad: En las entregas posteriores se evaluará experimentalmente el *Speedup* $S_p = T_1/T_p$ y la eficiencia paralela $E_p = S_p/p$ para $p \in \{1, 2, 4, 8, 16\}$ hilos, modelando el techo teórico mediante la Ley de Amdahl.

6. Conclusiones

La propuesta presentada delimita con precisión el problema derivado de la esparcidad masiva y la extrema concentración de popularidad en MovieLens 32M (95.70 % en el Top 10 %). La integración relacional de TMDB permite enriquecer semánticamente el catálogo para mitigar el arranque en frío. La arquitectura desacoplada en dos fases (Two-Tower y MMR) fundamenta teóricamente la viabilidad del proyecto, garantizando un consumo acotado de memoria y estableciendo una base idónea para la implementación de paralelismo en C/C++ con OpenMP y vectorización SIMD.

Referencias

[1] Harper, F. M., & Konstan, J. A. (2015). *The MovieLens Datasets: History and Context*. ACM Transactions on Interactive Intelligent Systems (TiiS), 5(4), 1–19[cite: 29].

[2] Koren, Y., Bell, R., & Volinsky, C. (2009). *Matrix Factorization Techniques for Recommender Systems*. IEEE Computer, 42(8), 30–37[cite: 12].

[3] Covington, P., Adams, J., & Sargin, E. (2016). *Deep Neural Networks for YouTube Recommendations*. Proceedings of the 10th ACM Conference on Recommender Systems (RecSys '16), 191–198.

[4] He, X., Liao, L., Zhang, H., Nie, L., Hu, X., & Chua, T. S. (2017). *Neural Collaborative Filtering*. Proceedings of the 26th International Conference on World Wide Web (WWW '17), 173–182.

[5] Liang, D., Krishnan, R. G., Hoffman, M. D., & Jebara, T. (2018). *Variational Autoencoders for Collaborative Filtering*. Proceedings of the 2018 World Wide Web Conference (WWW '18), 687–696.

[6] Kang, W. C., & McAuley, J. (2018). *Self-Attentive Sequential Recommendation*. IEEE International Conference on Data Mining (ICDM '18), 197–206.

[7] Steck, H. (2019). *Embarrassingly Shallow Autoencoders for Sparse Data*. Proceedings of the World Wide Web Conference (WWW '19), 3251–3257.

[8] Yi, X., Yang, J., Hong, L., Cheng, D. Z., Heldt, L., Kumthekar, A., Zhao, Z., Wei, L., & Chi, E. (2019). *Sampling-Bias-Corrected Neural Modeling for Large Corpus Item Recommendations*. Proceedings of the 13th ACM Conference on Recommender Systems (RecSys '19), 269–277[cite: 20].

[9] He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020). *LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation*. Proceedings of the 43rd International ACM SIGIR Conference, 639–648.

[10] Carbonell, J., & Goldstein, J. (1998). *The Use of MMR, Diversity-Based Reranking for Reordering Documents and Producing Summaries*. Proceedings of the 21st Annual International ACM SIGIR Conference, 335–336.

[11] OpenMP Architecture Review Board. (2018). *OpenMP Application Programming Interface Version 5.0*. Technical Report.